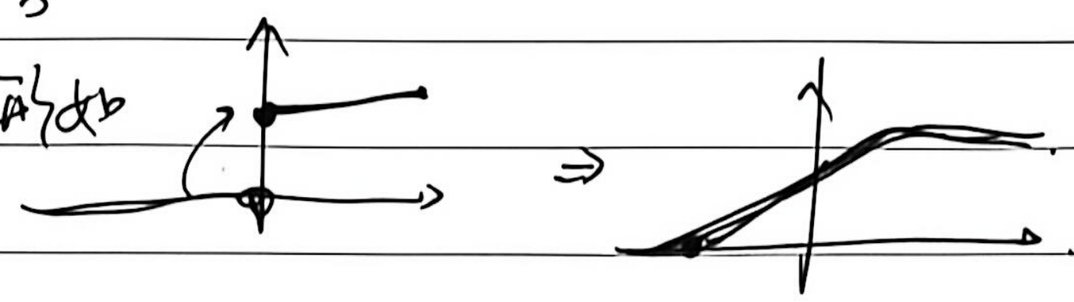
常见神经网络结构.

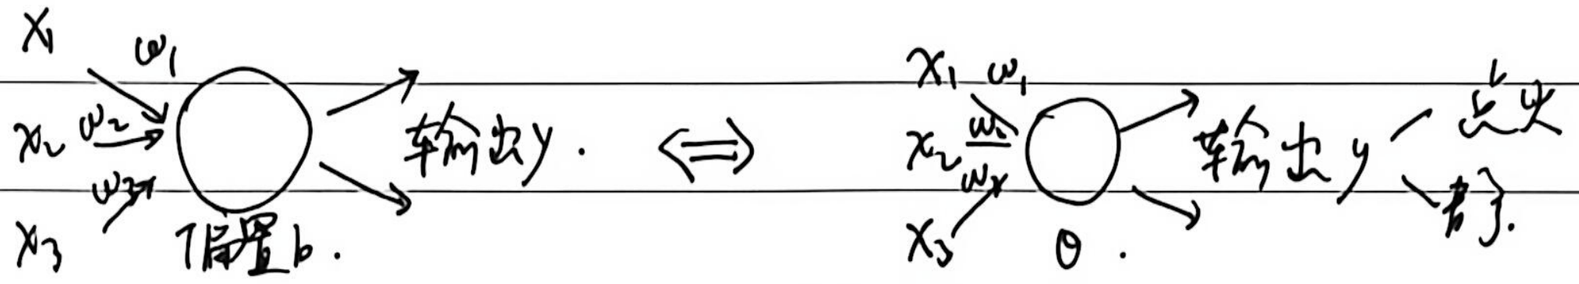
Date 9/20. 深度学习中的数学

卷积型　　卷积.

激活函数　形如

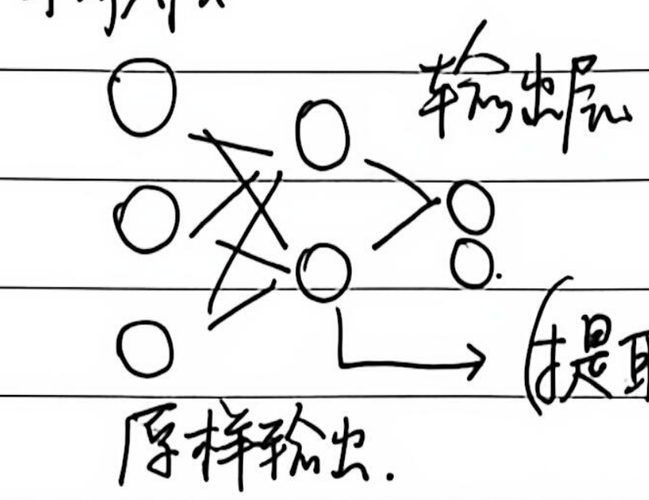


Sigmoid　$\sigma(z)=\frac{1}{1+e^{-z}}$



layer 层.

全连接层.



特征提取
feature extraction
↓
(提取输入图像的特征作用)

深度学习　卷积神经网络.
↳ 叠加了很多层的神经网络.

神经单元 → 神经网络.

预估
连接方式.

模式识别的难点在于答案不标准.

↳ solution: 由网络进行判断.

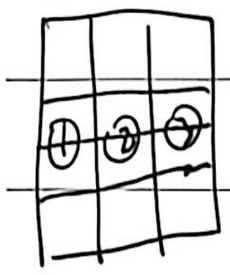
deli

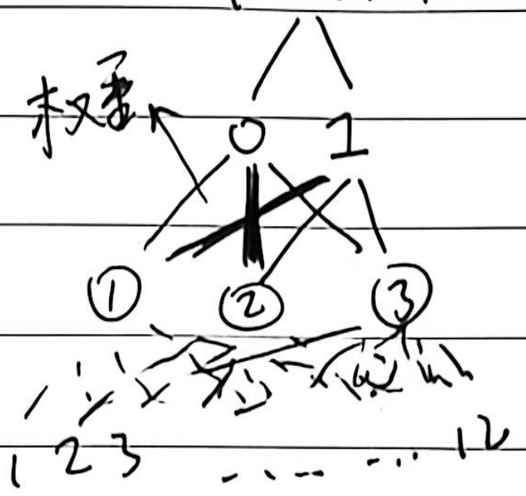
扫描全能王
3亿人都在用的扫描App

Date

总体意向.

例





中间的干扰 → Noise ✓

(每个Unit能正常传递信息的能力)

通过训练.强化有效的对应连接.

一种学习 ↗

改变权重.

更有可能-亚相关的

↳ 权重大

> 那为什么要有隐藏层? 直接考虑12个对应不行吗?

Guess: 可能数据更多、更多时、有负面效果?

事实上权重并非事先确定、而是网络自学习算法来确定

预测 vs. 正解: 最优化. ↳ 误差总和达min.

↳ 误差总和: 代价函数 cost function, C_T.

平方误差.

↓

最小二乘法: 利用平方误差确定参数的方法 (回归分析).

扫描全能王 3亿人都在用的扫描App

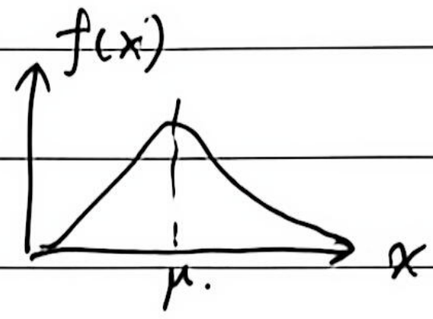
Date

误差反向传播法？

单位阶跃函数　　Sigmoid. $\sigma(x)=\frac{1}{1+e^{-x}}$.

初始值、正态分布.

有何用处？



联立递推关系式. 多个数列的递推关系式联合为一组.

形如
$a_1=1$..

计算机擅长. $a_{n+1}=(n+1)a_n$.

内积 $\vec{a}\cdot\vec{b}$

柯西-施瓦茨不等式: $-|\vec{a}||\vec{b}|\le\vec{a}\cdot\vec{b}\le|\vec{a}||\vec{b}|$.

梯度下降法: ←→ 同学方向完全相反

表示多大程度上指向相同方向. 越相似、内积越大.

tensor 张量.　　张力 → 在截面产生应力.

作用在(x,y,z)面上的力: $\begin{pmatrix}\tau_{11}\\ \tau_{21}\\ \tau_{31}\end{pmatrix}\cdot\begin{pmatrix}\tau_{12}\\ \tau_{22}\\ \tau_{32}\end{pmatrix}\cdot\begin{pmatrix}\tau_{13}\\ \tau_{23}\\ \tau_{33}\end{pmatrix}\Rightarrow\begin{pmatrix}\tau_{11}&\tau_{12}&\tau_{13}\\ \tau_{21}&\tau_{22}&\tau_{23}\\ \tau_{31}&\tau_{32}&\tau_{33}\end{pmatrix}$.

人工学习系统: TensorFlow的原理?

智能　　用到附带多个下标的变量

deli

扫描全能王 3亿人都在用的扫描App

Date

关于矩阵

· Hadamard 乘积 一一对应相乘

例: $A=\begin{pmatrix}2&7\\1&8\end{pmatrix}$, $B=\begin{pmatrix}2&8\\1&3\end{pmatrix}$

$$A\odot B=\begin{pmatrix}2\cdot2&7\cdot8\\1\cdot1&8\cdot3\end{pmatrix}=\begin{pmatrix}4&56\\1&24\end{pmatrix}$$

· 转置: ${}^tA$ or A^t / A^T 行列交换

例: $A=\begin{pmatrix}2&7\\1&8\end{pmatrix}$ $A^T=\begin{pmatrix}2&1\\7&8\end{pmatrix}$

关于导数 $\frac{dy}{dx}$.

Sigmoid

$$\sigma(x)=\frac{1}{1+e^{-x}} \Rightarrow \sigma'(x)=\sigma(x)(1-\sigma(x))$$

· $f(x)$ 在 $x=a$ 处取 min $\Rightarrow f'(a)=0$.

扫描全能王 3亿人都在用的扫描App

Date

关于偏导数

有两个以上的自变量的函数 ⇒ 多变量函数

指定对哪个自变量求导

偏导数 $\frac{\partial z}{\partial x}$ $z=f(x,y)$ 把 y 当常数 关于 求一个自变量的偏导数

↳ 把其他自变量当作常数

在神经网络中.

★ $z=wx+b$, $\frac{\partial z}{\partial x}=w$, $\frac{\partial z}{\partial w}=x$, $\frac{\partial z}{\partial b}=1$

例:

当 $z=w_1x_1+w_2x_2+b_1$, 求关于 x_1、w_2、b_1 偏导数.

$\frac{\partial z}{\partial x_1}=w_1$. $\frac{\partial z}{\partial w_2}=x_2$. $\frac{\partial z}{\partial b_1}=1$.

☆ $z=f(x,y)$ 取 min 的条件: $\frac{\partial z}{\partial x}=0$. $\frac{\partial z}{\partial y}=0$.

→ 拉格朗日乘数法.

例: $x^2+y^2=1$, 求 $x+y$ 最小值.

构造 $L=f(x,y)-\lambda g(x,y)=(x+y)-\lambda(x^2+y-1)$.

$\Rightarrow \frac{\partial L}{\partial x}=1-2\lambda x=0$, $\frac{\partial L}{\partial y}=1-2\lambda y=0$.

再由 $x^2+y^2=1$, 可得 $x=y=\pm\frac{\sqrt{2}}{2}=\lambda$ 故 $x,y=-\frac{\sqrt{2}}{2}$ 时取最小

deli

扫描全能王 3亿人都在用的扫描App

Date

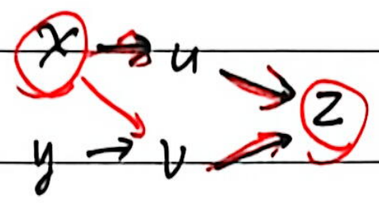
误差反向传播法必需的链式法则.

$$y = a(\underbrace{w_1x_1 + w_2x_2 + \cdots + w_nx_n + b}_{z})$$

激活函数

$\frac{dy}{dx} = \frac{dy}{du} \cdot \frac{du}{dx}$ 复合函数求导公式 → 链式法则.

例: 对于 $z = f(u, v)$. $u = g(x)$. $v = h(y)$



$$\frac{\partial z}{\partial x} = \frac{\partial z}{\partial u} \cdot \frac{\partial u}{\partial x} + \frac{\partial z}{\partial v} \cdot \frac{\partial v}{\partial x}.$$

例: $C = u^2 + v^2 + w^2$. $u = a_1x + b_1y + c_1z$, $v = a_2x + b_2y + c_2z$.

$w = a_3x + b_3y + c_3z$.

$$\frac{\partial C}{\partial x} = \frac{\partial C}{\partial u} \cdot \frac{\partial u}{\partial x} + \frac{\partial C}{\partial v} \cdot \frac{\partial v}{\partial x} + \frac{\partial C}{\partial w} \cdot \frac{\partial w}{\partial x}$$

$$= 2u \cdot a_1 + 2v \cdot a_2 + 2w \cdot a_3$$

扫描全能王 3亿人都在用的扫描App

Date

梯度下降法的基础：多变量函数近似公式

$f(x+\Delta x) \doteqdot f(x)+f'(x)\Delta x$ → $f'(x)=\lim\limits_{\Delta x\to 0}\dfrac{f(x+\Delta x)-f(x)}{\Delta x}$

↓

$f(x+\Delta x, y+\Delta y) \doteqdot f(x,y)+\dfrac{\partial f(x,y)}{\partial x}\Delta x+\dfrac{\partial f(x,y)}{\partial y}\Delta y.$

例：$z=e^{x+y}$. 求 $x=y=0$ 附近的近似公式

$z \doteqdot e^{x+y}+e^{x+y}\Delta x+e^{x+y}\Delta y$

$\Delta x\to x,\ \Delta y\to y$

$\Rightarrow x=y=0,\ e^{x+y}\doteqdot 1+x+y.$

⇒近似公式的向量表示

例：$\Delta z \doteqdot \dfrac{\partial z}{\partial w}\Delta w+\dfrac{\partial z}{\partial x}\Delta x+\dfrac{\partial z}{\partial y}\Delta y.$

$\nabla z=\left(\dfrac{\partial z}{\partial w},\dfrac{\partial z}{\partial x},\dfrac{\partial z}{\partial y}\right)\cdot\Delta x=(\Delta w,\Delta x,\Delta y)$

近似公式的一般化公式：泰勒展开式

$$f(x+\Delta x,y+\Delta y)=f(x,y)+\frac{\partial f}{\partial x}\Delta x+\frac{\partial f}{\partial y}\Delta y+\frac{1}{2!}\left\{\frac{\partial^2 f}{\partial x^2}(\Delta x)^2+2\frac{\partial^2 f}{\partial x\partial y}\Delta x\Delta y+\frac{\partial^2 f}{\partial y^2}(\Delta y)^2\right\}+\cdots$$

deli

扫描全能王 3亿人都在用的扫描App

Date

梯度下降法的思路：

如果要求函数在何处取最小值.

↳ 移动图像上的点，慢慢摸索.

梯度 $\left(\frac{\partial f(x,y)}{\partial x}, \frac{\partial f(x,y)}{\partial y}\right)$ $\vec{a}$ $(\Delta x, \Delta y)$ $\vec{b}$ 位移向量.

$\Rightarrow \Delta z = \frac{\partial f(x,y)}{\partial x}\Delta x + \frac{\partial f(x,y)}{\partial y}\Delta y.$

由前文可得 $\vec{a}$、$\vec{b}$ 方向相反时，$\vec{a}\cdot\vec{b}$ 取最小值.

∇：哈密顿算子 (nabla)　　$\nabla f = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \cdots, \frac{\partial f}{\partial x_n}\right)$.

$\Rightarrow \Delta x = -\eta \nabla f$

↳ 学习率